

FUNDACAO GETULIO VARGAS

ESCOLA DE ECONOMIA DE SÃO PAULO

**MESTRADO PROFISSIONAL EM FINANÇAS E ECONOMIA
EMPRESARIAL**

MODELO DE PREVISAO DE INFLAÇÃO NO BRASIL

AURELIEN LORTHIOIS

**SÃO PAULO
FEVEREIRO 2009**

AURELIEN LORTHIOIS

MODELO DE PREVISAO DE INFLAÇÃO NO BRASIL

Dissertação apresentada à Escola de Economia de São Paulo da Fundação Getúlio Vargas, como requisito para obtenção do título de Mestre em Finanças e Economia Empresarial.

Campo de conhecimento:
Economia e econometria.

Orientador: Prof. Marcio Holland de Brito

SÃO PAULO
FEVEREIRO 2009

LORTHIOIS, Aurélien.

Modelo de Previsão de Inflação no Brasil / Aurélien LORTHIOIS - 2009.
40 f.

Orientador: Marcio Holland de Brito.

Dissertação (mestrado profissional) - Escola de Economia de São Paulo.

1. Inflação - previsão. 2. Inflação – Brasil - Modelos econométricos. 3.
Política monetária - Brasil. I. Brito, Marcio Holland. II. Dissertação (mestrado
profissional) - Escola de Economia de São Paulo. III. Título.

CDU 336.748.12(81)

AURELIEN LORTHIOIS

MODELO DE PREVISÃO DE INFLAÇÃO NO BRASIL

Dissertação apresentada à Escola de Economia de São Paulo da Fundação Getúlio Vargas, como requisito para obtenção do título de Mestre em Finanças e Economia Empresarial.

Campo de conhecimento:
Economia e econometria.

Data de aprovação:
04/02/2009

Banca Examinadora:

Prof. Marcio Holland de Brito (Orientador)
FGV – EAESP

Prof. Claudio Ribeiro de Lucinda
FGV – EAESP

Prof. Fabio Augusto Reis Gomes
IBMEC – SP

SÃO PAULO
FEVEREIRO 2009

Dedico este trabalho aos meus pais, aos meus irmãos e à minha noiva pelo aprendizado e apoio que sempre me deram aos meus estudos.

AGRADECIMENTOS

Agradeço ao meu orientador, professor Marcio Holland de Brito, pelo aprendizado, idéias e paciência.

Agradeço ao professor Paulo Picchetti que foi o primeiro a me motivar a estudar este tema utilizando ferramentas econométricas.

Agradeço aos meus colegas do banco Itaú, Tomás Málaga e Adriana Monteiro Gonçalves e a professora Maria Carolina Leme que me motivaram a continuar meus estudos em economia e fazer este mestrado.

Agradeço aos meus colegas da área internacional do banco CIC, em especial ao Luiz Fernando Mendes de Almeida Jr e Patrice Gasser pelo apoio aos estudos.

Agradeço aos meus amigos, Renato Santaniello, João M Salles e José Diogo Valadares pelas sugestões de *papers* e idéias.

Agradeço aos colegas da turma do mestrado Elia Matsumoto, Rodrigo Albuquerque, Danilo Guedine Serafini e Sebastián Arbeleche pelas idéias e discussões.

Agradeço à equipe de intercâmbio da FGV, em especial Paula Mello e Daniela Seixas e Delphine Lefebvre da faculdade em Paris que me auxiliaram a realizar o intercâmbio na ESSEC.

Agradeço a todos àqueles que direta ou indiretamente contribuíram para o este trabalho.

RESUMO

No Brasil, o regime de metas para inflação foi instituído em julho de 1999, pelo Banco Central do Brasil, sendo o principal objetivo ancorar as expectativas de mercado. Este regime levou a uma queda da inflação e também a uma convergência das expectativas. Quando comparadas com a inflação ocorrida, as expectativas do mercado melhoraram nos últimos anos, porém, continuam com um erro ainda expressivo para o prazo de 6 meses. Em linhas gerais, a contribuição desta dissertação é de mostrar que existem modelos simples que conseguem prever o comportamento da inflação em médio prazo (6 meses). Um modelo ARIMA do IPCA obtém projeções acumuladas de inflação melhores que as projeções do mercado.

Palavras-chave: Inflação, Previsão, ARIMA.

ABSTRACT

In July 1999, the inflation targeting was implemented by the Brazilian Central Bank, in which the major objective was to guide the market expectations. This regime reduced the inflation and converged the expectations. Although, when compared the inflation accumulated for six month and its market expectation there is still a difference between them. The contribution of this work is that we can construct simple models for inflation that project the inflation in the medium term. An autoregressive moving average model of the official inflation in Brazil can project better than the market.

Keywords: Inflation, Forecast, ARIMA.

SUMARIO

1. Introdução	10
2. Inflação e suas projeções	11
3. Metodologia Econométrica	14
3.1 Médias Moveis Auto-Regressivas ARMA	14
3.2 Metodologia Box&Jenkins.....	17
4. Modelos Econométricos	19
4.1 A Variável IPCA	19
4.2 A Estimação de um modelo sem variável <i>dummy</i>	23
4.3 A Estimação de um modelo com variável <i>dummy</i>	27
5. Considerações finais	32
6. Bibliografia	34
7. Apêndice	36

1 – Introdução

O Regime de Metas¹ para a Inflação é um regime monetário no qual o Banco Central se compromete a atuar de forma a garantir que a inflação observada esteja em linha com uma meta pré-estabelecida, anunciada publicamente. O governo adotou o Regime de Metas para Inflação em julho de 1999. Um dos objetivos deste regime é ancorar as expectativas de mercado que orientam o processo de formação de preços na economia. Semanalmente o Banco Central do Brasil divulga a mediana das expectativas de inflação e sua dispersão dos agentes econômicos. Esta é acompanhada pelo mercado com atenção para conhecer a evolução esperada deste índice, pois afeta importantes indicadores do mercado financeiro tais como a curva de juros.

Será que a pesquisa Focus teria que acertar a previsão de inflação? Pois, se as expectativas são racionais, os agentes econômicos deveriam levar em conta a reação do Banco Central do Brasil dada a previsão do mercado. Por exemplo, se a previsão do mercado é de uma elevação da inflação, a reação do Banco Central é de reduzir a liquidez para manter a inflação na meta. Caso o Banco Central tenha sucesso nesta reação a inflação ficará na meta e os agentes econômicos terão errado a previsão.

Este regime levou a uma queda da inflação e a uma convergência das expectativas. Quando comparadas com a inflação ocorrida, as expectativas do mercado melhoraram nos últimos anos, porém continuam com um erro ainda expressivo para prazo acumulado de 6 meses. Utilizando dados da pesquisa Focus do Banco Central do Brasil, comparamos a expectativa de inflação para os próximos 6 meses (considerando a previsão no último dia útil de cada mês) e a inflação ocorrida. Podemos ver que existe uma relação entre as variáveis (ver gráfico 1).


O objetivo desta dissertação é obter um modelo simples que possa prever a inflação para os próximos seis meses e compará-lo com a inflação ocorrida e com a expectativa do mercado. Em linhas gerais, a contribuição desta dissertação é de mostrar que existem modelos simples que conseguem prever o comportamento da inflação em médio prazo.

Em nossos resultados mais relevantes, podemos antecipar que um modelo ARIMA do IPCA com ou sem dummy podem obter projeções acumuladas de inflação melhores que as projeções do mercado.

¹ Baseado no artigo "Regime de Metas para a Inflação no Brasil"(2007) da Gerência-Executiva de Relacionamento com Investidor do Banco Central do Brasil

Na seção 2, descrevemos a inflação e suas projeções. A seção 3 trata da metodologia utilizada. Na seção 4 descrevemos a variável IPCA, estimamos os modelos e comparamos os resultados. As considerações finais estão no item 5. No item 6 disponibilizamos a referência bibliográfica, seguida do apêndice.

Gráfico 1 – Inflação prevista (6 meses à frente) versus ocorrido



Fonte : BCB e IBGE

2 – Inflação e suas projeções

Segundo BEVILACQUA, MESQUITA e MINELLA (2007), as expectativas de inflação são variáveis importantes para os modelos de previsão de inflação do Banco Central. Além disto, as expectativas de inflação vêm sendo influenciadas pela inflação passada, pela meta de inflação, taxa de câmbio, evolução do preço das *commodities*, atividade econômica e pela política monetária. As expectativas davam probabilidade maior de 50% ao intervalo superior da meta, fazendo com que a média da distribuição ficasse acima do centro da meta. Durante as ultimas crises de confiança, a inflação passada tinha um peso importante para a previsão de inflação. Nos últimos tempos, esta variável vem perdendo importância, pois dados empíricos sugerem que na equação de inflação o parâmetro da inflação passada vem perdendo importância em relação ao da inflação esperada.

Isto nos leva a crer que a credibilidade do sistema de metas de inflação reduz o efeito do passado da inflação.

Uma forma de estimar a inflação pode ser baseada em MELLO DE CARVALHO e CASTRO DE SOUZA (2006) que estimam a equação para as expectativas de inflação, seguido de uma estrutura a termo da taxa de juros. Utilizando estes resultados os autores estimam a curva IS, que representa a relação entre o hiato do produto e taxa de juros, e em seguida estima uma curva de Phillips, que representa a relação entre o hiato de produto e inflação. A expectativa utilizada é a da inflação 12 meses à frente em função da política monetária, meta de inflação para os próximos 12 meses, uma medida de risco país, da própria expectativa de inflação do período anterior, da dinâmica da taxa de câmbio e da inflação corrente. Neste artigo, a previsão de inflação é dinâmica, isto é, apenas para 1 mês à frente, que explica o alto grau de acerto.

Outro modelo pode ser ilustrado com ALVES (2001) que avalia o desempenho do modelo estrutural de pequena escala do Banco Central com a projeção trimestral da inflação para 1 a 3 trimestres a frente. Este modelo foi comparado com as projeções do mercado (Focus) e com um modelo simplificado. O modelo estrutural se mostrou mais eficiente para projeções até 3 trimestres. Os dados utilizados são trimestrais e com hipótese de juros fixo. Os modelos simples considerados foram basicamente os seguintes ARIMA, VAR, Near VAR, utilizando SUR (Seemingly unrelated regressions). Para modelagem VAR, utilizou-se a teoria econômica para a determinação inicial das variáveis consideradas endógenas ao sistema. A taxa de inflação é diretamente explicada pelo hiato do produto. Porém, outros indicadores são essenciais para a explicação da inflação, seja direta ou indiretamente e, provavelmente, com alguma defasagem. As projeções um período à frente se mostraram boas tanto para o modelo estrutural quanto para as previsões de mercado.

ALENCAR (2006) analisou e comparou diversos modelos econométricos de previsão de inflação com o objetivo de verificar qual modelagem é capaz de realizar melhores previsões no curto prazo. Foram eles, ARIMA, ARCH, EGARCH, ADL e VAR. O modelo ARIMA apresentou boa capacidade de previsão de um passo à frente fora da amostra. O parâmetro de comparação adotado para escolha foi a raiz do erro quadrático médio e a conclusão é que a modelagem VAR demonstrou-se muito eficaz nas previsões e em corroborar as teorias econômicas mas os modelos ARCH e EGARCH são os mais eficazes nas previsões fora da amostra no curto prazo.

ARARIPE (2008) analisou a capacidade de previsão de inflação dos modelos econométricos ARMA, ADL, VAR e VECM no período de até 12 meses e também estudar seus efeitos de combinação de previsões. A abordagem univariada Box-Jenkins pode fornecer uma ótima previsão com uma amostra suficientemente grande, mas a grande restrição é que não necessitam de fundamentação econômica, pois é apenas utilizado o passado para a previsão. O autor conclui que

os modelos VAR e VECM se mostraram superiores em termos de erro quadrático médio tanto em relação aos modelos ARMA e ADL quanto em relação ao próprio FOCUS. A combinação de previsões, principalmente via regressão linear múltipla se mostrou bastante eficiente na redução dos erros quadráticos médios das previsões fora da amostra.

Por outro lado, podemos estimar modelos mais simples para prever a inflação como o artigo do do banco central da Irlanda de MEYLER, KENNY e QUINN (2008). A principal vantagem das projeções ARIMA é que é necessária apenas a série da variável em questão. Primeiro, esta é uma vantagem caso esta é utilizada para projeções de outras variáveis. Segundo, evita o problema que pode ocorrer em modelos multivariados em que nem todos os dados têm a mesma periodicidade e histórico disponível. Entre as principais desvantagens das projeções ARIMA temos que muitas técnicas de identificação de modelo são subjetivas e a fiabilidade pode depender da experiência da pessoa que está fazendo a projeção. Segundo, não está associada a nenhum modelo teórico ou estrutura entre as variáveis. O significado econômico do modelo escolhido não é tão claro. Finalmente, modelos ARIMA são essencialmente com base no histórico, desta forma, dificilmente prevêem mudanças estruturais, exceto se este ponto representar um retorno ao equilíbrio de longo prazo. Os resultados são surpreendentemente robustos quando comparados com modelos multivariados. De fato, STOCKTON e GLASSMAN (1987) encontraram resultados semelhantes para os Estados Unidos e consideram que um simples modelo ARIMA de inflação pode se tornar uma projeção de respeitável desempenho relativamente aos modelos teóricos baseados em especificações.

No Brasil, LIMA e CESPEDDES (2003) testaram se os agentes econômicos e o Banco Central do Brasil são bons preditores da taxa de inflação em diversos horizontes. A taxa de inflação é medida pelo Índice de Preços ao Consumidor Amplo (IPCA), utilizado pelo Banco Central para fixar suas metas de inflação. Os modelos lineares estimados para comparar foram: auto-regressivo com duas defasagens (AR(2)), auto-regressivo com cinco defasagens (AR(5)), ARIMA (0,1,2) e ARIMA (2,1,4). Não há evidência que o mercado (FOCUS) ou o Banco Central, em seus relatórios, prevejam a inflação com razoável grau de acurácia em horizontes suficientemente longos para nortear a política monetária. Os modelos lineares superam o mercado em habilidade preditiva para previsões superiores a três meses à frente, inclusive com as Top 5 (curto, médio e longo prazo). Este artigo apresenta resultados bastante surpreendentes. As expectativas divulgadas pelo mercado têm significativa influência na curva de juros e também na formulação da política monetária do país. Mas se os modelos lineares superam o mercado, porque não é dada tanta importância a estes modelos. Uma interpretação é que as previsões de mercado se concentram na inflação do próximo mês e a inflação esperada de mais longo prazo é em grande parte prevista com o centro da meta divulgada pelo Banco Central.

3 – Metodologia Econométrica²

Segundo o número de parâmetros envolvidos, podemos classificar os modelos para séries temporais em duas classes. Modelos paramétricos em que o número de parâmetros é finito e os modelos não paramétricos, que envolvem um número infinito de parâmetros. Entre os modelos paramétricos a análise é feita no domínio do tempo. Dentre estes modelos os mais frequentemente usados são os modelos auto-regressivos e de médias móveis (ARMA) e os modelos auto-regressivos integrados e de médias móveis (ARIMA)

Modelos estacionários são aqueles que assumem que o processo gerador dos dados está em "equilíbrio". Um processo é considerado fracamente estacionário se suas média e variância se mantêm constantes ao longo do tempo e a função de autocovariância depende apenas da defasagem entre os instantes de tempo. Um processo é fortemente estacionário se todos os momentos conjuntos não variarem no tempo.

3.1 Médias Moveis Auto-Regressivas ARMA

Em um modelo auto-regressivo, a série de dados A_t é descrita por seus valores passados regredidos e pelo ruído aleatório ε_t . Assim, um modelo AR(p) é dado por:

$$\tilde{A}_t = \phi_1 \tilde{A}_{t-1} + \phi_2 \tilde{A}_{t-2} + \dots + \phi_p \tilde{A}_{t-p} + \varepsilon_t \quad (1)$$

em que:

$$\tilde{A}_t = A_t - \mu;$$

ϕ_i é o parâmetro que descreve como \tilde{A}_t se relaciona com o valor para $\tilde{A}_{t-i} = 1, 2, \dots, p$

O modelo AR(p) dado pela equação (1) pode ser reescrito como a equação (2), utilizando o operador de defasagem L (aplicando o operador de defasagem em A_{t-3} temos $L^3 A_t$).

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) \tilde{A}_t = \phi(L) \tilde{A}_t = \varepsilon_t \quad (2)$$

O modelo auto-regressivo de ordem 1 é a versão mais simples e pode ser representado pela equação (3):

$$\tilde{A}_t = \phi \tilde{A}_{t-1} + \varepsilon_t \quad (3)$$

² A metodologia baseada em MORETTIN, P. A e TOLOI (2004) e WERNER e RIBEIRO (2005)

Para o modelo ser estacionário é necessário que $|\zeta_1| < 1$ (condição de estacionariedade) e que as autocovariâncias (ζ_k) sejam independentes. No caso do modelo AR(1), as autocovariâncias são dadas por:

$$\gamma_k = \phi_1^k \gamma_0 \quad (4)$$

e as autocorrelações ζ_k são dadas pela equação (5):

$$\rho = \frac{\gamma}{\gamma_0} = \phi_1^k; k = 0, 1, 2, \dots \quad (5)$$

A função de autocorrelação diminui exponencialmente quando ζ_1 é positivo; quando ζ_1 é negativo, a função de autocorrelação também diminui exponencialmente, mas apresenta alternância de sinais positivos e negativos.

Por outro lado, em modelos de médias móveis (do inglês *moving average*), a série A_t resulta da combinação dos ruídos brancos e do período atual com aqueles ocorridos em períodos anteriores. Assim, um modelo de médias móveis de ordem q ou MA(q) é dado por:

$$\tilde{A}_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (6)$$

em que:

$$\tilde{A}_t = A_t - \mu$$

ζ_i é o parâmetro que descreve como A_t se relaciona com o valor ζ_{t-i} para $i = 1, 2, \dots, q$.

O modelo MA(q) dado pela equação (6) pode ser reescrito, como em (7), utilizando o operador de defasagem L.

$$(1 - \theta_1 L - \theta_2 L^2 - \dots - \theta_q L^q) \varepsilon_t = \theta(L) \varepsilon_t = \tilde{A}_t \quad (7)$$

O modelo MA(1) é a versão mais simples dessa classe de modelos. Sua apresentação algébrica é dada pela equação (8):

$$\tilde{A}_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (8)$$

As autocorrelações ζ_k , que nada mais são do que as autocovariâncias divididas pela variância

são dadas por:

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{-\theta_1 \sigma_\varepsilon^2}{(1+\theta_1^2)\theta_\varepsilon^2} = \frac{-\theta_1}{(1+\theta_1^2)} \quad \text{e} \quad \rho_k = 0; k > 1 \quad (9)$$

A função de autocorrelação do modelo MA(1) apresenta apenas a primeira autocorrelação não-nula e as demais iguais a zero. A primeira auto-correlação será positiva se ζ_1 for menor que zero e negativa se ζ_1 for maior que zero.

Segundo NELSON (1973) uma propriedade importante da MA(1), proveniente da função de autocorrelação, é que sua "memória" é de somente um período. Para obter a condição de invertibilidade, isto é, para transformar um modelo MA(1) em um modelo AR, é preciso impor a restrição de que $|\zeta_1| < 1$. Segundo ABRAHAM & LEDOLTER (1983), para que um processo MA(q) se torne inversível, é necessário que as raízes da equação abaixo sejam maiores que um:

$$\zeta(L) = (1 - \zeta_1 L - \zeta_2 L^2 - \dots - \zeta_p L^p) = 0$$

E algum caso convém utilizar componentes de um modelo AR com componentes de um modelo MA, gerando um modelo ARMA. O modelo ARMA(p,q) exigirá um número menor de termos e pode ser expresso conforme a equação (10):

$$\tilde{A}_t = \phi_1 \tilde{A}_{t-1} + \dots + \phi_p \tilde{A}_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q} \quad (10)$$

O modelo ARMA mais simples é o ARMA(1,1), como segue:

$$\tilde{A}_t = \phi_1 \tilde{A}_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1} \quad (11)$$

A função de autocorrelação do modelo ARMA(1,1) é dada por:

$$\rho_1 = \frac{(1-\phi_1\theta_1)(\phi_1-\theta_1)}{1+\theta_1^2+2\phi_1\theta_1} \quad \text{e} \quad \rho_k = \phi_1 \rho_{k-1} \quad \text{para } k > 1 \quad (12)$$

A função de autocorrelação do modelo ARMA(p,q) apresenta características da função MA(q) para as defasagens $k < q$, pelo fato de a "memória" do componente de médias móveis durar apenas q períodos. Para defasagens maiores que $k + 1$ as características são iguais às de um modelo AR(p).

3.2 Metodologia Box & Jenkins

Segundo MORETTIN & TOLOI (1987), a construção dos modelos Box-Jenkins é baseada em um ciclo iterativo, no qual a escolha do modelo é feita com base nos próprios dados. Segundo BOX & JENKINS (1976), são três as etapas para construção do modelo.

A primeira é a *Identificação* que corresponde a encontrar o modelo que melhor descreve o comportamento da série seja dentre as várias versões dos modelos de Box-Jenkins, sejam eles sazonais ou não. A identificação depende do comportamento das funções de autocorrelações (ACF) e das funções de autocorrelações parciais (PACF). Em seguida, a *Estimação* dos parâmetros f e F do componente auto-regressivo, assim como os parâmetros q e Q do componente de médias móveis e a variância de e_t . E finalmente, a *verificação* que avalia se o comportamento dos dados está bem representado pelo modelo estimado.

Caso o modelo não seja adequado, o ciclo é repetido, voltando-se à fase de identificação. Um procedimento muito utilizado é identificar não só um único modelo, mas alguns modelos que serão então estimados e verificados. Quando se obtém um modelo satisfatório, passa-se para a última etapa da metodologia de Box-Jenkins, que constitui o objetivo principal da metodologia: realizar previsões.

Segundo Box Jenkins (1976), o previsor h passos a frente para modelo auto regressivo é dado por:

$$\hat{A}_t(h) = \phi_1^h A_t + \mu - \mu\phi_1^h \quad (13)$$

Onde $\hat{A}_t(h)$ é a previsão h passos a frente com base no tempo t ; ϕ_1 é o coeficiente da variável em estudo defasada um período; e μ , a média do processo.

Nesta dissertação, vamos apresentar dois tipos de previsão, a primeira consiste em prever a inflação para os próximos 6 meses, isto é a equação (13) em que $h = 1$ até 6 para o mesmo t . Este modelo é conhecido como modelo estático, pois realizamos projeções para os próximos períodos mantendo dada a mesma informação inicial. A segunda forma consiste em prever para cada t , a inflação para o próximo mês, isto é a equação (13) em que $h = 1$. Neste caso, são feitas 6 projeções para $t=1$ até 6. Este é o modelo dinâmico em que as previsões acabam errando menos pois é apenas realizada previsão um passo a frente, e então o erro quadrático médio tende a ser menor.

A principal vantagem das projeções ARIMA é que é necessária apenas a série da variável em questão. Além disto, evita o problema que pode ocorrer em modelos multivariados em que nem todos os dados têm a mesma periodicidade e histórico disponível. Entre as principais desvantagens das projeções ARIMA, temos que muitas técnicas de identificação de modelo são

subjetivas e a fiabilidade pode depender da experiência da pessoa que está fazendo a projeção. Segundo, não está associada a nenhum modelo teórico ou estrutura entre as variáveis. O significado econômico do modelo escolhido não é tão claro. Finalmente, modelos ARIMA são essencialmente com base no histórico, desta forma, dificilmente prevêem quebras na série, exceto se este ponto representar um retorno ao equilíbrio de longo prazo.

Vamos apresentar as principais estatísticas e suas explicações para que serão utilizadas na metodologia Box & Jenkins.

Os critérios de informação que veremos abaixo punem pelo acréscimo de regressores ao modelo. São eles AKAIKE (AIC) e SCHWARZ (SC).

O critério de AKAIKE é definido como

$$AIC = e^{2k/n} \cdot SQR / n$$

Em que k é o número de regressores (incluindo o intercepto) e n é o número de observações. Ao comparar os dois modelos, o escolhido será aquele que apresentar o menor AIC.

Outra particularidade importante desta estatística é que esta é útil não apenas no caso do desempenho do modelo em termos de previsões dentro da amostra, mas também para aquelas fora da amostra.

A estatística SCHWARZ, é semelhante ao AIC, o critério SC é definido como:

$$SC = n^{k/n} \cdot SQR / n$$

Esta estatística apresenta uma punição mais dura que a anterior. Assim como o AIC, ao comparar dos dois modelos, o escolhido será aquele que apresentar o menor valor. Além disto, o SC pode ser empregado para comprar o desempenho do modelo em termos de previsão dentro e fora da amostra.

Além disto, a estatística Durbin Watson é usada para detectar a presença de auto correlação nos resíduos³.

Por exemplo, seja e_t o resíduo associado com a observação no tempo t , o teste é definido da seguinte forma:

³ O resultado fica entre 0 e 4. Um valor próximo a 2 indica que este modelo não aparenta ter autocorrelação. Porém, este testa apenas um processo autorregressivo de primeira ordem, ou seja, um AR(1) dos resíduos.

$$d = \frac{\sum_{t=2}^T (e_t - e_{t-1})^2}{\sum_{t=1}^T e_t^2}$$

4 – Modelos Econométricos

4.1 A variável IPCA

Como parte do processo de implantação do regime de metas de inflação, em 1999, coube ao Banco Central do Brasil iniciar um processo de pesquisa de expectativas de inflação. Tais expectativas são obtidas através da Pesquisa de Expectativas de Mercado, iniciada em maio de 1999. Seu objetivo é monitorar a evolução do consenso de mercado para as principais variáveis macroeconômicas, de forma a gerar subsídios para o processo decisório da política monetária. Na medida em que o Banco Central do Brasil anuncia sua estratégia de política monetária, seus movimentos tornam-se mais previsíveis ao mercado. A partir do momento em que a política monetária ganha credibilidade, os reajustes de preços tendem a ser próximos à meta⁴.

O Comitê de Política Monetária, COPOM, é o órgão decisório da política monetária do Banco Central do Brasil. Ele é responsável por estabelecer a meta para a taxa Selic. A taxa Selic, é a taxa de juros média que incide sobre os financiamentos diários com prazo de um dia útil (overnight) lastreado por títulos públicos registrados no Sistema Especial de Liquidação e de Custódia (Selic). O objetivo do COPOM é o alcance das metas de inflação estabelecidas pelo Conselho Monetário Nacional (CMN). Em outubro 2005, o COPOM anunciou a redução de reuniões de 1 a cada 30 dias para 1 a cada 45 dias a partir de Janeiro 2006.

Como parte da operacionalização deste novo regime monetário o Banco Central do Brasil estabeleceu que a medida de inflação seria o IPCA (Índice Nacional de Preços ao Consumidor Amplo) calculado pelo IBGE (Instituto Brasileiro de Geografia e Estatística). O período de coleta do IPCA estende-se, em geral, do dia 01 a 30 do mês de referência. A população-objetivo do IPCA abrange as famílias com rendimentos mensais compreendidos entre 1 (hum) e 40 (quarenta) salários-mínimos, qualquer que seja a fonte de rendimentos, e residentes nas áreas urbanas das regiões. Sua periodicidade é mensal e a coleta é feita nas regiões metropolitanas de Belém,

Fortaleza, Recife, Salvador, Belo Horizonte, Rio de Janeiro, São Paulo, Curitiba e Porto Alegre, Brasília e município de Goiânia.


A escolha de um índice de preços ao consumidor é freqüente na maioria dos regimes de metas para inflação, pois é a medida mais adequada para avaliar a evolução do poder aquisitivo da população. O índice cheio do IPCA foi escolhido por ter cobertura nacional e a maior abrangência. A adoção do índice cheio se explica por dois motivos. Primeiro, embora no longo prazo o núcleo e a inflação tendam a convergir, no curto prazo podem divergir significativamente. O segundo é a transparência e credibilidade sobre o cálculo do núcleo de inflação que poderia gerar dúvidas na sociedade.

A inflação apresenta uma dinâmica diferente entre os preços livres e preços administrados. Os preços administrados são reajustados na maioria das vezes com base em contratos prévios e representaram 33,63% do IPCA em junho 2006. Além disto, os preços livres têm características distintas sendo eles comercializáveis (*tradables*) e não comercializáveis (*non tradables*). Os primeiros são influenciados principalmente pelos movimentos do câmbio e preço das commodities. E os chamados não comercializáveis respondem principalmente a movimentos da demanda interna.

O IPCA é dividido em 9 subgrupos. São eles: alimentação e bebidas, habitação, artigos de residência, vestuário, transportes, saúde e cuidados pessoais, despesas pessoais, educação e comunicação (ver abaixo gráfico 2). Os grupos de maior importância são alimentação e transportes, seguido de habitação, saúde e despesas pessoais. Em julho de 2006, o IPCA passa a ser calculado tendo por base as ponderações atualizadas, que foram obtidas a partir dos resultados da pesquisa de Orçamentos Familiares – POF, realizada de julho de 2002 a julho de 2003. Isto levou a uma queda da participação dos subgrupos: transportes, habitação e alimentação e aumento da participação de: educação e comunicação.

⁴ Baseado no artigo “Regime de Metas para a Inflação no Brasil”(2007) da Gerência-Executiva de Relacionamento com Investidor do Banco Central do Brasil

Gráfico 2 – Participação dos grupos no IPCA



Fonte : IBGE

Algumas séries apresentam uma sazonalidade importante. Podemos citar: educação, com o reajuste das mensalidades escolares no início do ano e comunicação até 2005 (ver gráfico 3 no apêndice). O subgrupo Comunicação apresenta maior variabilidade, seguindo de Saúde e habitação (ver abaixo tabela 1).


Tabela 1 – Média, Mediana e Desvio Padrão por grupo do IPCA

Índice geral			
1.Alimentação e bebidas	0,46	0,58	0,49
2.Habitação	0,96	0,64	0,53
3.Artigos de residência	0,55	0,55	0,42
4.Vestuário	0,61	0,32	0,25
5.Transportes	0,59	0,54	0,60
6.Saúde e cuidados pessoais	0,99	0,64	0,40
7.Despesas pessoais	0,46	0,51	0,42
8.Educação	0,49	0,56	0,50
9.Comunicação	1,25	0,58	0,20
Fonte: IBGE			

Por outro lado, em todos os subgrupos, a média é diferente da mediana, o que nos mostra que as distribuições mostram assimetria. Por exemplo, se a média do grupo Alimentação e bebidas é maior que a mediana, isto mostra que a série tem outliers acima da média. Dentre os 9 grupos, todas têm esta característica, exceto o grupo Transporte que apresenta uma mediana superior a média.

Os dados do IPCA utilizados correspondem à variação mensal de Agosto 1999 até junho 2008, obtidos no site do IBGE. Ao visualizar o gráfico da série variação em IPCA podemos dizer que esta parece ser estacionária (ver abaixo gráfico 4).

Gráfico 4 – Variação em IPCA (mensal)



Fonte : IBGE

Ao analisar as funções de auto-correlação da série, o correlograma nos leva as seguintes conclusões. Em primeiro lugar, existe auto-correlação nos dados e esta desaparece após 4 meses. Além disto, existe auto-correlação parcial em relação ao mês anterior. Este é um indício de que um modelo AR(1) ajustaria esta série (ver tabela 2 no apêndice). Finalmente, ao realizar o teste Dickey Fuller, rejeitamos a hipótese nula de que esta série é integrada de primeira ordem e ela é então estacionária (ver tabela 3 no apêndice).

O regime de metas classifica mensalmente as instituições com melhores previsões dentre aquelas participantes da pesquisa de mercado. Esta classificação visa destacar as instituições que têm sido mais consistentes no acerto das previsões por meio dos rankings Top 5 de curto, médio e longo prazo.

O ranking⁵ é elaborado para as seguintes variáveis econômicas: o IPCA, o IGP-M, o IGP-DI, a taxa Selic e a taxa de câmbio. No ranking de curto prazo, avalia-se a precisão das projeções com defasagens de um mês em relação à publicação do indicador, nos últimos 6 meses. O ranking de médio prazo considera a precisão média das projeções de três períodos consecutivos de 4 meses em relação aos resultados efetivos de três meses – o mês de referência e os dois meses que o antecedem. O ranking de longo prazo considera a precisão das projeções informadas em 12 meses para o indicador anual publicado no mês de janeiro subsequente. Para os rankings de curto e médio prazo, além da divulgação mensal, divulgam-se rankings anuais com base nos desvios mensais referentes a cada um dos meses do ano civil, de janeiro a dezembro.

Para ilustrar esta metodologia, no ranking entre os participantes da pesquisa de expectativa de mercado em dezembro 2007⁶, o erro referente à projeção do IPCA do primeiro colocado foi de 0,06 para Top Five de curto prazo, 0,099 para Top Five de médio prazo e 0,3807 para Top Five de longo prazo. Isto mostra o alto grau de acerto destas instituições.

4.2 A Estimação de um modelo sem variável dummy

Os primeiros modelos estimados não utilizam variáveis *dummy* que poderiam amenizar os efeitos dos choques como, por exemplo, o ano de 2002. Ao estimar os modelos AR, MA e ARMA, escolhemos o modelo de menor critério de informação que corresponde ao AR(1) com constante (ver tabelas 3, 4 e 5 no apêndice).

O melhor modelo estimado⁷ considera uma constante de coeficiente 0,579 e o coeficiente do AR(1) de 0,644 (ver tabela 6). Os critérios de informação deste modelo foram de 0,805932 para o AKAIKE e 0,856185 para SCHWARZ. Ambos critérios tiveram o AR(1) como melhor modelo.

⁵ Baseado no artigo “Instituições Top 5 - Classificação Anual para as Categorias Curto e Médio Prazo e Consolidação da Metodologia”

⁶ Relação de instituições TOP 5 Dezembro 2007, Banco Central do Brasil (janeiro 2008)

⁷ Os critérios de informação Akaike e Schwarz deste modelo foram os menores dentre os modelos testados. E o resultado da estatística Durbin Watson foi de 1,90, portanto, o modelo aparenta não ter autorrelação.

Tabela 7 - Modelo sem variável dummy

Dependent Variable: IPCA				
Method: Least Squares				
Sample (adjusted): 1999M09 2008M06				
Included observations: 106 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.579582	0.097872	5.921.824	0.0000
AR(1)	0.644023	0.075090	8.576.670	0.0000
R-squared	0.414280	Mean dependent var		0.576509
AdjustedR-squared	0.408648	S.D. dependent var		0.466431
S.E. of regression	0.358683	Akaike info criterion		0.805932
Sum squared resid	1.337.996	Schwarz criterion		0.856185
Log likelihood	-4.071.438	F-statistic		7.355.926
Durbin-Watson stat	1.905.833	Prob(F-statistic)		0.000000
Inverted AR Roots	.64			

Poderíamos comparar o coeficiente do AR(1) da forma reduzida com a forma estrutural, isto é, a primeira parte da curva de Phillips. HOLLAND e MORI (2008) a descrevem da seguinte forma:


$$\pi_t = \alpha\pi_{t-1} + (1 - \alpha)\pi_t^e + \beta h_t^d + \gamma(\pi_t^m - \pi_t^e) \quad (14)$$

Sendo π_t a taxa de inflação corrente, π_{t-1} a taxa de inflação do período t-1, π_t^e a expectativa de inflação, h_t^d o hiato do produto doméstico, e o choque de oferta medido pelo desvio da inflação em preço de importações e inflação esperada que é dado por: $(\pi_t^m - \pi_t^e)$.

Em nosso modelo, o coeficiente α da equação (14) nos diz que um aumento em 1% na inflação no período anterior, *ceteris paribus*, aumenta a inflação corrente em 0,64%. Isto corresponde a inércia inflacionária no Brasil. Em ALENCAR (2006), este coeficiente é de 0,67% e em CARVALHO SOUZA (2006), este é de 0,567 para a inflação dos bens comercializáveis.

Seguindo a metodologia Box Jenkins, precisamos agora fazer o diagnóstico do comportamento dos resíduos. Em geral, os resíduos estão dentro da banda. Podemos ver que existem dois picos, sendo o primeiro no ano de 2000 e o segundo em 2002 (ver abaixo no gráfico 5).

Gráfico 5 – Variabilidade dos resíduos



Em julho de 2000, a inflação atingiu 1,61% naquele mês explicado principalmente pelos efeitos de problemas climáticos sobre a produção agrícola aliados à entre safra, ao reajuste nos derivados de petróleo e aos reajustes nas tarifas de telefone e energia elétrica. Segundo GOLDFAJN (2003) os principais fatores da crise de 2002 foram (i) o aumento da aversão ao risco que é mensurado pelo risco país, (ii) a redução da entrada de capital estrangeiro no Brasil e (iii) a desvalorização do Real sobre o dólar americano.


Além disto, é importante verificar se existe correlação nos resíduos.

Neste caso, não rejeitamos a hipótese nula de que não existe correlação serial nos resíduos (ver tabela 7 no apêndice). Portanto, este modelo se ajusta de forma adequada a esta série do IPCA.

Finalmente, chegamos à última fase da metodologia Box Jenkins na qual faremos a projeção do IPCA utilizando duas formas. A primeira é chamada de modelo estático em que fixamos uma data sendo a última com dados da inflação ocorrida e faremos a projeção para os próximos 6 meses. Neste caso, temos a inflação ocorrida até dezembro 2007 e a projeção começa a partir de janeiro de 2008 até junho de 2008 utilizando a amostra que se inicia em agosto de 1999. A previsão de inflação mensal para cada um dos meses ficou entre 0,55% e 0,7%. O erro entre a previsão do modelo e o IPCA de fato é conhecido por erro quadrático médio que ficou em 0,145861 (ver gráfico 6 no apêndice).

Podemos comparar nossas previsões para esta amostra com a inflação ocorrida e as projeções do FOCUS, inclusive as que mais acertam (TOP 5 de curto, médio e longo prazo) (Ver tabela 8). Em dezembro 2007, as expectativas de inflação do mercado estavam com uma tendência de queda para os próximos 6 meses, bem mais intensa do que realmente ocorreu. Neste caso, podemos ver que a expectativa de inflação calculada pelo modelo proposto está mais próxima do ocorrido do que a previsão do mercado, principalmente quando comparamos com a inflação acumulada em 6 meses (ver abaixo no gráficos 7).

Gráfico 7 – Comparativo entre IPCA e previsões AR(1) e Focus (estático)




Fonte : BCB e IBGE

A segunda forma de projeção é o modelo dinâmico em que é feita a previsão de inflação utilizando toda a amostra até o dado anterior. Neste caso, o erro tende a ser menor, pois a cada previsão o modelo é novamente calibrado com um dado adicional de inflação. A previsão de inflação mensal para cada um dos meses ficou entre 0,50% e 0,75% com uma curva em formato de U. Porém, o erro quadrático médio que foi reduzido e atingiu 0,1160 (ver gráfico 9 no apêndice).

Novamente, podemos comparar nossas previsões para esta amostra com a inflação ocorrida e as projeções do FOCUS em dezembro 2007 (ver tabela 9 no apêndice). As previsões neste caso, não demonstram uma tendência de queda generalizada, mas uma previsão em queda até o terceiro mês que é revertida com uma alta do terceiro até o sexto mês (ver gráfico 10 e 11 no apêndice).

Isto é, quando comparamos a previsão de inflação em dezembro de 2007 para os próximos seis meses, a previsão era de queda até junho. Porém, a partir do mês de março 2008, as previsões do mercado já apontavam para um aumento da inflação. No caso de nossa projeção, podemos ver que esta é antecipada de forma mais rápida que o mercado. Podemos concluir que tanto na projeção estática quanto na dinâmica, o modelo AR(1) tem uma projeção melhor que a expectativa de mercado Focus (inclusive Top 5).

Gráfico 10 Comparativo entre IPCA e previsões AR (1) e Focus (Dinâmico)



Fonte : BCB e IBGE

4.3 A Estimação de um modelo com variável dummy

Os próximos modelos estimados utilizam variáveis dummy, com valores 1 nos dois picos de inflação (julho 2000 e novembro 2002) e zero nos outros períodos. Estimamos da mesma forma que no item anterior, os ARs, MAs e ARMAs e escolhemos o modelo que apresenta menor critério de informação (ver tabelas 10, 11 e 12 no apêndice).

Após testar as diferentes formas, o AR(1) com constante e dummy foi o melhor modelo⁸. Este considera uma constante de coeficiente 0,558, um coeficiente da dummy de 1,129 e o coeficiente do AR(1) de 0,667 (ver abaixo tabela13), todos eles significativamente diferentes de zero. Os critérios de informação deste modelo foram de 0,504195 para o AKAIKE e 0,579575 para SCHWARZ. Ambos critérios tiveram o AR(1) como melhor modelo.

Tabela 14 - Modelo com variável dummy

Dependent Variable: IPCA				
Method: Least Squares				
Sample (adjusted): 1999M09 2008M06				
Included observations: 106 after adjustments				
		Std.		
Variable	Coefficient	Error	t-Statistic	Prob.
C	0.558613	0.089809	6.220.038	0.0000
DUM	1.129356	0.180994	6.239.744	0.0000
AR(1)	0.667676	0.073607	9.070.847	0.0000
R-squared	0.574937	Mean dependent var		0.576509
AdjustedR-squared	0.566683	S.D. dependent var		0.466431
S.E. of regression	0.307037	Akaike info criterion		0.504195
Sum squared resid	9.709.970	Schwarz criterion		0.579575
	-			
Log likelihood	2.372.233	F-statistic		6.965.855
Durbin-Watson stat	1.949.535	Prob(F-statistic)		0.000000
Inverted AR Roots	.67			

Seguindo a metodologia Box Jenkins, precisamos agora fazer o diagnóstico do comportamento dos resíduos. Em geral, os resíduos estão menos voláteis, pois os picos foram amenizados (ver gráfico 12). Além disto, é importante verificar se existe correlação nos resíduos.


Neste caso, não rejeitamos a hipótese nula de que não existe correlação serial nos resíduos (ver tabela 14 em apêndice). Portanto, este modelo também se ajusta de forma adequada a esta série do IPCA.

Finalmente, chegamos a última fase da metodologia Box Jenkins na qual faremos a projeção do IPCA utilizando o modelo estático e o dinâmico. No primeiro caso, temos a inflação ocorrida até dezembro 2007 e a projeção começa a partir de janeiro de 2008 até junho de 2008 utilizando a amostra que se inicia em agosto de 1999. A previsão ficou entre 0,55 e 0,70%. O erro quadrático médio ficou em 0,148185 (ver gráfico 13 no apêndice). Podemos comparar nossas previsões para esta amostra com a inflação ocorrida e as projeções do FOCUS em dezembro 2007, inclusive as que mais acertam (TOP 5 de curto, médio e longo prazo) (ver tabela 15 no apêndice).

⁸ Os critérios de informação Akaike e Schwarz deste modelo foram os menores dentre os modelos testados. E o resultado da estatística Durbin Watson foi de 1,9495, portanto, o modelo aparenta não ter autorrelação.


As conclusões são semelhantes ao primeiro modelo sem dummy. As expectativas de inflação do mercado estavam com uma tendência de queda para os próximos 6 meses, bem mais intensa do que realmente ocorreu ao comparar com a inflação ocorrida. Neste caso, podemos ver que a expectativa de inflação calculada pelo modelo proposto está mais próxima do ocorrido do que a previsão do mercado, principalmente quando comparamos com a inflação acumulada em 6 meses (ver abaixo gráficos 14 e 15). Podemos notar também que as projeções dos modelos AR(1) com e sem dummy são muito semelhantes.

Gráfico 14 Comparativo entre IPCA e previsões AR(1) e Focus (estático)



Fonte : BCB e IBGE

Gráfico 15 Comparativo acumulado entre IPCA e previsões AR(1) e Focus (estático)




Fonte : BCB e IBGE

Por outro lado, as projeções com modelo dinâmico, em que é feita a previsão de inflação utilizando toda a amostra até o dado anterior, a previsão também ficou entre 0,50% e 0,75% com uma curva em formato de U. No caso dinâmico, o erro quadrático médio ficou em 0,1173 (ver gráfico 16 no apêndice).

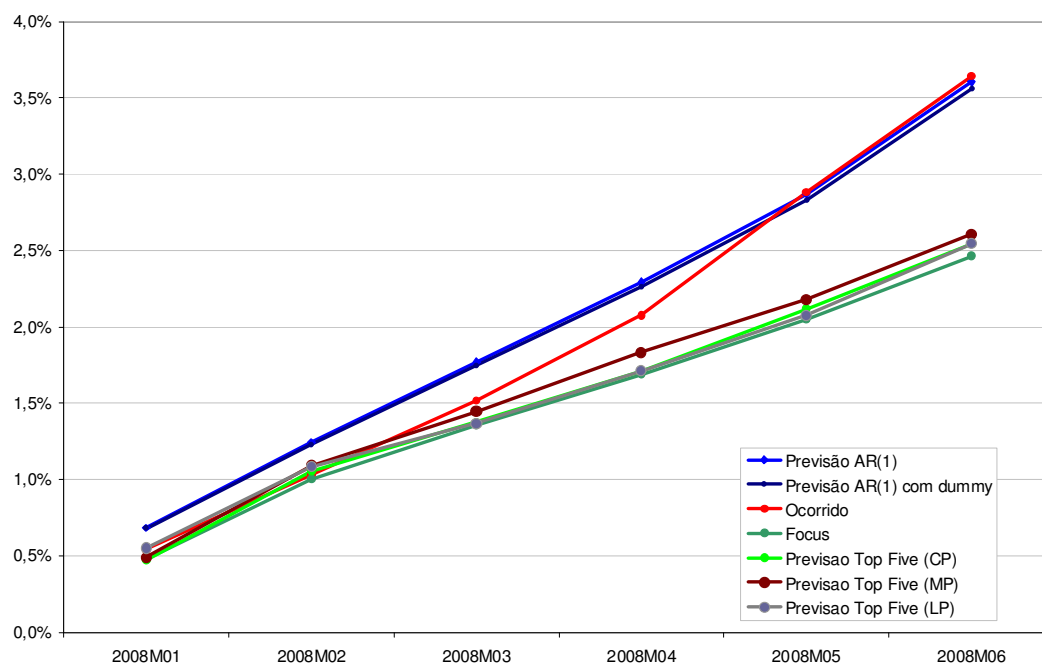
Novamente, ao comparar nossas previsões para esta amostra com a inflação ocorrida e as projeções do FOCUS (Ver tabela 16 em apêndice). As previsões neste caso, não demonstram uma clara tendência de queda como no modelo estático. Isto é, obtivemos uma previsão em queda até o terceiro mês que é revertida com uma alta do terceiro até o sexto mês (ver abaixo gráfico 17 e 18). Podemos concluir que tanto na projeção estática quanto na dinâmica, o modelo AR(1) tem uma projeção melhor que a expectativa de mercado Focus (inclusive Top 5).

Gráfico 17 Comparativo entre IPCA e previsões AR(1) e Focus (dinâmico)



Fonte : BCB e IBGE

Gráfico 18 Comparativo acumulado entre IPCA e previsões AR(1) e Focus (dinâmico)



Fonte : BCB e IBGE

5 – Considerações finais

No Brasil, o regime de metas para inflação levou a uma queda da inflação e também a uma convergência das expectativas. Quando comparadas com a inflação ocorrida, as expectativas do mercado melhoraram nos últimos anos, porém continuam com um erro ainda expressivo para prazo de 6 meses. O objetivo desta dissertação era de mostrar que existem modelos simples que conseguem prever o comportamento da inflação em médio prazo (6 meses). A principal vantagem dos modelos ARMA é que são modelos simples e apenas a série da variável em questão é necessária para estimarmos o modelo. Por outro lado, sabemos que existem limitações a este tipo de modelo, pois o significado econômico do modelo escolhido não é tão claro e dificilmente prevêm-se quebras na série.

A previsão da inflação utilizando a metodologia Box&Jenkins com um modelo ARMA, com ou sem dummy, nos levou a resultados surpreendentes e positivos em que a previsão de inflação para os próximos seis meses tem melhor poder preditivo do que pesquisa Focus. As previsões são muito parecidas quando é utilizada variável dummy. Além disto, o erro quadrático médio na previsão é levemente inferior quando não utilizamos variáveis dummies (ver tabela 17 no apêndice). A inflação acumulada de janeiro à junho 2008 foi de 3,81% sendo que nossa previsão estática era de 3,64% contra 2,22% da previsão dos que mais acertam no mercado (Top 5). Isto é, o modelo estimado antecipou a elevação da inflação antes que os analistas de mercado.

Os resultados encontrados em nosso modelo ARMA são semelhantes aos resultados de MEYLER, A. et al (1998) e de Stockton e Glassman (1987). Estes encontraram resultados parecidos respectivamente para Irlanda e para os Estados Unidos em que um simples modelo ARIMA de inflação pode se tornar uma projeção de respeitável desempenho relativamente aos modelos teóricos baseados em especificações.

Segundo BEVILACQUA, MESQUITA e MINELLA (2007), o sistema de metas de inflação tem por objetivo ancorar as expectativas e existem evidências de que a política monetária contribuiu para um cenário mais estável e previsível. Além disto, existem sinais de que a incerteza sobre da inflação declinou. Estabilidade de preço é uma condição básica para um maior crescimento sustentável. Para planejamento de longo prazo, porém, é necessário não apenas que os agentes econômicos sintam-se confortáveis com as projeções de média ou mediana de inflação, mas também, que a probabilidade de *outliers* (tanto para cima quanto para baixo) seja baixa. Existem evidências que o sistema evoluiu neste sentido. Uma prova disto, é que além de divulgar as medianas das expectativas, o banco central do Brasil também divulga a distribuição de probabilidade das expectativas.

A questão que fica é então porque os especialistas do mercado não utilizam um modelo simples para prever o IPCA? Uma pista seria de fato as críticas as projeções ARIMA e suas limitações de significado econômico. Vimos nos artigos ALENCAR B. K. (2006) e ARARIPE (2008) modelos VAR, ARCH e EGARCH são os mais eficazes nas previsões. Outra possível interpretação seria que as previsões de mercado se concentram na inflação do próximo mês e a inflação esperada de mais longo prazo é em grande parte prevista com o centro da meta divulgada pelo Banco Central. Finalmente, fica a pergunta, será que a previsão Focus teria que acertar ou será que esta previsão é um insumo adicional de acompanhamento das expectativas e conseqüentemente de decisão do Banco Central? Vale ressaltar que realizamos o teste para o período de janeiro a junho de 2008. Seria interessante realizar este mesmo teste com uma janela móvel para analisar se o modelo ARIMA continua sendo um bom modelo de previsão.

6 – Referências bibliográficas

ABRAHAM, B.; LEDOLTER, J. *Statistical methods for forecasting*. New York: John Wiley & Sons, 1983.

ALENCAR, B. K. *Modelos de previsão da inflação: uma análise comparativa no curto prazo*. Dissertação de mestrado profissionalizante em economia. IBMEC RJ (julho 2006).

ALVES, S.A. L. *A Avaliação das projeções do modelo estrutural do Banco Central do Brasil para a taxa de variação do IPCA* – Trabalhos para discussão WP 16 (março 2001).

ARARIPE, A. A. *Prevendo inflação usando series temporais e combinações de previsões*. Dissertação de mestrado em finanças e economia. FGV-EPGE (agosto 2008).

Banco Central do Brasil, Gerência-Executiva de Relacionamento com Investidor – Série Perguntas mais freqüentes: “Regime de metas para a inflação no Brasil” – Setembro 2007.

Banco Central do Brasil, Gerência-Executiva de Relacionamento com Investidor – Série Perguntas mais freqüentes: “Copom” – Agosto 2005.

Banco Central do Brasil, Gerência-Executiva de Relacionamento com Investidor – Série Perguntas mais freqüentes: “Índice de Preços” – Junho 2006.

Banco Central do Brasil, Gerência-Executiva de Relacionamento com Investidor – Série Perguntas mais freqüentes: “Preços Administrados” – Setembro 2006.

Banco Central do Brasil, Gerência-Executiva de Relacionamento com Investidor – Instituições Top 5 - Classificação Anual para as Categorias Curto e Médio Prazo e Consolidação da Metodologia – 2008.

BEVILACQUA, A.S e MESQUITA, M e MINELLA, A. *Brazil: Taming Inflation Expectations* – Trabalhos para discussão WP 129 (janeiro 2007).

BOX, G. E. P.; JENKINS, G. M. *Time series analysis forecasting and control*. San Francisco: Holden- Day, 1976. Edição revisada.

GOLDFAJN, I. *The Brazilian Crisis, the Role of the IMF and Democratic Governability*. Rio de Janeiro: PUC, 2003, mimeo.

GREENE, W. H. *Econometric Analysis*. 3rd Ed., New Jersey: Prentice Hall, 1997.

GUJARATI, D. *Econometria Básica*. 4rd Ed., Rio de Janeiro: Elsevier, 2006.

HOLLAND, M. e MORI, R. *Dinâmica da Inflação no Brasil e os Efeitos Globais*. FGV-EESP, 2008.

Instituto Brasileiro de Geografia e Estatística – IBGE – “Sistema Nacional de Índices de Preços ao Consumidor, Estrutura de Ponderação a partir da Pesquisa de Orçamentos Familiares 2002-2003” – Série Relatórios Metodológicos – Volume 34, 2005.

LIMA, E. C. R. e CESPEDES, B. J. V. *O desempenho do mercado (focus) e do Bacen na previsão da inflação: comparações com modelos lineares univariados* – IPEA – Boletim de conjuntura (mar 2003).

MELLO DE CARVALHO, L. e CASTRO DE SOUZA JR, J. R. *Modelo para previsão de inflação* IPEA – Boletim de conjuntura (mar 2006).

MEYLER, A. , KENNY G. e QUINN T. *Forecasting Irish Inflation using ARIMA models*. Economic Analysis, Research and Publications Department, Central bank of Ireland, 1998.

MORETTIN, P. A. e TOLOI, C. M. C. . *Análise de Séries Temporais*. 2. ed. São Paulo: Editora Blucher, 2006.

MORETTIN, P. A.; TOLOI, C. M. C. *Previsão de séries temporais*. 2.ed. São Paulo: Atual Editora, 1987.

NELSON, C. R. *Applied time series analysis for managerial forecasting*. San Francisco: Holden-Day, 1973.

SOUZA Jr, J. R. C. *Produto Potencial: conceitos, métodos de estimação e aplicação à economia brasileira*. Rio de Janeiro: IPEA, 2005 (Texto para discussão, 1130).


STOCKTON, D., e GLASSMAN, J., 1987. *Evaluation of the Forecast Performance of Alternative Models of Inflation*”, Review of Economics and Statistics, Vol 69, No1, February, pp. 108-117.

WERNER, L. ; RIBEIRO, J.L.D. *Demand forecasting: an application of the Box-Jenkins models in the technical assistance of personal computer*, Universidade Federal de São Carlos (2005)

Apêndice – Gráficos

Anexos

Gráfico 3 – Variabilidade dos grupos no IPCA



Fonte : IBGE

Gráfico 6 – Projeção do IPCA do modelo estático





Gráfico 8 – Comparativo acumulado entre IPCA e previsões AR(1) e Focus



Fonte : BCB e IBGE

Gráfico 9 – Projeção do IPCA do modelo dinâmico





Gráfico 11 - Comparativo acumulado entre IPCA e previsões AR(1) e Focus



Fonte : BCB e IBGE

Gráfico 12 – Variabilidade dos resíduos




Gráfico 13 – Projeção do IPCA do modelo estático





Gráfico 16 – Projeção do IPCA do modelo dinâmico



Apêndice – Tabelas

Tabela 2 – Teste de raiz unitária

Null Hypothesis: IPCA has a unit root Exogenous: Constant, Linear Trend Lag Length: 0 (Automatic based on SIC, MAXLAG=12)				
			t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic			-4,8541	0,0007
Test critical values:	1% level		-4,0469	
	5% level		-3,4528	
	10% level		-3,1519	
*MacKinnon (1996) one-sided p-values.				
Augmented Dickey-Fuller Test Equation				
Dependent Variable: D(IPCA)				
Method: Least Squares				
Sample (adjusted): 1999M09 2008M06				
Included observations: 106 after adjustments				
	Coefficient	Std. Error	t-Statistic	Prob.
IPCA(-1)	-0,37419	0,07709	-4,85406	0
C	0,28167	0,09137	3,08262	0,0026
@TREND(1999M08)	-0,00121	0,00117	-1,03751	0,3019
R-squared	0,1862	Mean dependent var		0,0017
Adjusted R-squared	0,1704	S.D. dependent var		0,39366
S.E. of regression	0,35855	Akaike info criterion		0,8144
Sum squared resid	13,24157	Schwarz criterion		0,88978
Log likelihood	-40,1634	Hannan-Quinn criter.		0,84496
F-statistic	11,7834	Durbin-Watson stat		1,89197
Prob(F-statistic)	0,00003			

Tabela 3 – Autocorrelação e autocorrelação parcial IPCA

Sample: 1999M08 2008M06 Included observations: 107				
	Auto correlation	Partial Correlation		
1	0.642	0.642	45	0
2	0.373	-0.065	61	0
3	0.285	0.122	70	0
4	0.220	0.000	75	0
5	0.071	-0.146	76	0
6	-0.011	-0.007	76	0
7	-0.092	-0.121	77	0
8	-0.021	0.183	77	0
9	0.048	0.051	77	0
10	0.010	-0.077	77	0

Tabela 4 – Modelos Autoregressivos – AR

	Constante	Coeficiente do AR	Constante	Akaike info criterion	Schwarz criterion
AR(1)	sim	0,64	0,58	0,81	0,86
AR(1)	não	0,86	-	0,91	0,94
AR(2)	sim	0,37	0,58	1,2	1,25
AR(2)	não	0,76	-	1,43	1,45
AR(3)	sim	0,28	0,57	1,25	1,31
AR(3)	não	0,71	-	1,53	1,55
AR(4)	sim	0,22	0,57	1,29	1,34
AR(4)	não	0,68	-	1,6	1,62

Tabela 5 – Modelos MA

	Constante	Coeficiente do MA	Constante	Akaike info criterion	Schwarz criterion
MA(1)	sim	0,56	0,58	0,9	0,95
MA(1)	não	0,68	-	1,52	1,55
MA(2)	sim	0,28	0,58	1,22	1,27
MA(2)	não	0,5	-	1,83	1,85
MA(3)	sim	0,34	0,58	1,23	1,28
MA(3)	não	0,59	-	1,79	1,81
MA(4)	sim	0,3	0,58	1,27	1,31
MA(4)	não	0,65	-	1,8	1,82

Tabela 6 – Modelos ARMA

	Constante	Coeficiente do AR	Coeficiente do MA	Constante	Akaike info criterion	Schwarz criterion
ARMA(1,1)	sim	0,54	0,17	0,58	0,82	0,89
ARMA(1,1)	não	0,9	-0,13*	-	0,92	0,97
ARMA(2,2)	sim	0,5	-0,15	0,58	1,21	1,29
ARMA(2,2)	não	0,98	-0,76	-	1,31	1,37
ARMA(3,3)	sim	-0,04*	0,37*	0,58	1,26	1,33
ARMA(3,3)	não	0,98	-0,96	-	1,29	1,34
ARMA(4,4)	sim	-0,43	0,74	0,58	1,22	1,3
ARMA(4,4)	não	0,97	-0,95	-	1,29	1,34

* não significativos a 5%

Tabela 8 - Autocorrelação e autocorrelação parcial dos resíduos (do modelo da tabela 7)

Sample: 1999M09 2008M06 Included observations: 106				
Q-statistic probabilities adjusted for 1 ARMA term(s)				
	AC	PAC	Q-Stat	Prob
1	0,04	0,04	0,21	
2	-0,12	-0,12	1,69	0,19
3	0,04	0,05	1,83	0,4
4	0,14	0,12	3,95	0,27
5	-0,06	-0,06	4,31	0,37
6	-	0,03	4,31	0,51
7	-0,19	-0,22	8,5	0,2
8	-	0,02	8,5	0,29
9	0,13	0,1	10,39	0,24
10	-0,04	-0,04	10,53	0,31

Tabela 9 – Dados gráfico 7

Estático

			Focus Mediana			
	Previsão AR(1)	Ocorrido	Focus	Top five CP	Top five MP	Top five LP
2008M01	0,68%	0,54%	0,48%	0,47%	0,49%	0,55%
2008M02	0,65%	0,49%	0,45%	0,46%	0,49%	0,48%
2008M03	0,62%	0,48%	0,35%	0,35%	0,35%	0,31%
2008M04	0,61%	0,55%	0,30%	0,31%	0,38%	0,31%
2008M05	0,60%	0,79%	0,25%	0,26%	0,30%	0,30%
2008M06	0,59%	0,74%	0,21%	0,25%	0,23%	0,25%

*Previsão Focus em dezembro 2007

Tabela 10 - Dados gráfico 10

Dinâmico

			Focus Mediana			
	Previsão AR(1)	Ocorrido	Focus	Top five CP	Top five MP	Top five LP
2008M01	0,68%	0,54%	0,48%	0,47%	0,49%	0,55%
2008M02	0,55%	0,49%	0,52%	0,58%	0,60%	0,53%
2008M03	0,52%	0,48%	0,35%	0,32%	0,35%	0,28%
2008M04	0,52%	0,55%	0,33%	0,33%	0,38%	0,34%
2008M05	0,56%	0,79%	0,35%	0,40%	0,34%	0,36%
2008M06	0,72%	0,74%	0,41%	0,42%	0,42%	0,46%

Tabela 11 – Modelos Autoregressivos – AR

	Constante	Dummy	Coeficiente do AR	Constante	Akaike info criterion	Schwarz criterion
AR(1)	sim	1,13	0,67	0,56	0,5	0,58
AR(1)	não	1,09	0,89	-	0,6	0,66
AR(2)	sim	1,58	0,42	0,55	0,86	0,94
AR(2)	não	1,53	0,8	-	1,09	1,14
AR(3)	sim	1,68	0,33	0,54	0,92	0,99
AR(3)	não	1,64	0,77	-	1,18	1,23
AR(4)	sim	1,69	0,23	0,53	0,98	1,06
AR(4)	não	1,61	0,72	-	1,3	1,36

Tabela 12 – Modelos MA

	Constante	Dummy	Coeficiente do MA	Constante	Akaike info criterion	Schwarz criterion
MA(1)	sim	1,12	0,59	0,56	0,63	0,71
MA(1)	não	1,13	0,72	-	1,34	1,39
MA(2)	sim	1,64	0,33	0,55	0,89	0,97
MA(2)	não	1,79	0,57	-	1,58	1,63
MA(3)	sim	1,63	0,44	0,55	0,88	0,96
MA(3)	não	1,68	0,68	-	1,5	1,55
MA(4)	sim	1,63	0,31	0,55	0,97	1,04
MA(4)	não	1,56	0,66	-	1,59	1,64

Tabela 13 – Modelos ARMA

	Constante	Dummy	Coeficiente do AR	Coeficiente do MA	Constante	Akaike info criterion	Schwarz criterion
ARMA(1,1)	sim	1,09	0,61	0,10*	0,56	0,52	0,62
ARMA(1,1)	não	1,17	0,92	-0,19*	-	0,61	0,69
ARMA(2,2)	sim	1,58	0,5	-0,10*	0,55	0,88	0,98
ARMA(2,2)	não	1,62	0,96	-0,56	-	1	1,08
ARMA(3,3)	sim	1,66	-0,10*	0,51	0,54	0,9	1
ARMA(3,3)	não	1,67	0,99	-0,96	-	1,03	1,1
ARMA(4,4)	sim	1,58	-0,37*	0,65	0,54	0,96	1,06
ARMA(4,4)	não	1,69	0,98	-0,95	-	1,03	1,1

* não significativos a 5%

Tabela 15 - Autocorrelação e autocorrelação parcial dos resíduos (referente ao modelo da tabela 14)

Sample: 1999M09 2008M06 Included observations: 106				
Q-statistic probabilities adjusted for 1 ARMA term(s)				
	AC	PAC	Q-Stat	Prob
1	0,26	0,26	7,19	
2	0,06	-0,01	7,54	0,01
3	0,06	0,05	7,96	0,02
4	0,05	0,02	8,2	0,04
5	-0,02	-0,04	8,23	0,08
6	0,05	0,06	8,46	0,13
7	0,07	0,05	9,1	0,17
8	-0,06	-0,1	9,54	0,22
9	-0,11	-0,08	10,84	0,21
10	0,21	0,28	16,3	0,06

Tabela 16 - Dados gráfico 14

Estático (com dummy)

			Focus Mediana			
	Previsão AR(1)	Ocorrido	Focus	Top five CP	Top five MP	Top five LP
2008M01	0,68%	0,54%	0,48%	0,47%	0,49%	0,55%
2008M02	0,64%	0,49%	0,45%	0,46%	0,49%	0,48%
2008M03	0,61%	0,48%	0,35%	0,35%	0,35%	0,31%
2008M04	0,59%	0,55%	0,30%	0,31%	0,38%	0,31%
2008M05	0,58%	0,79%	0,25%	0,26%	0,30%	0,30%
2008M06	0,57%	0,74%	0,21%	0,25%	0,23%	0,25%

*Previsão Focus em dezembro 2007

Tabela 17 - Dados gráfico 17

Dinâmico (com dummy)

			Focus Mediana			
	Previsão AR(1)	Ocorrido	Focus	Top five CP	Top five MP	Top five LP
2008M01	0,68%	0,54%	0,48%	0,47%	0,49%	0,55%
2008M02	0,55%	0,49%	0,45%	0,46%	0,49%	0,48%
2008M03	0,51%	0,48%	0,35%	0,35%	0,35%	0,31%
2008M04	0,51%	0,55%	0,30%	0,31%	0,38%	0,31%
2008M05	0,55%	0,79%	0,25%	0,26%	0,30%	0,30%
2008M06	0,71%	0,74%	0,21%	0,25%	0,23%	0,25%

*Previsão Focus em dezembro 2007

Tabela 18 – Comparativo erro quadrático médio

Projeção		
<i>Root mean squared error</i>	Sem dummy	Com dummy
6 meses a frente (estático)	0,145861	0,148185
1 mês à frente (dinâmico)	0,116011	0,117358